

Modelo Seletivo Aprimorado para Modelagem de Amplificadores de Potência usando GMDH

Ana Paula Princival Machado¹, Eduardo Gonçalves de Lima²

¹ UFPR, Curitiba, Brasil

² UFPR, Curitiba, Brasil

anaprincival@ufpr.br

Resumo—No campo da elétrica voltado para telecomunicações há um dispositivo cuja principal finalidade é amplificar a potência de seu sinal de entrada e carregá-lo com alta eficiência energética: o amplificador de potência (PA). Em algumas situações seu sinal precisa ser linearizado e isso é feito através da aplicação de métodos de manipulação de dados (GMDH). O presente projeto apresenta a construção de dois códigos baseados no modelo GMDH que se diferenciam no seu método de análise, um sendo mais seletivo que o outro na escolha de neurônios. A partir do confronto de resultados, percebe-se que a arquitetura seletiva se sobressai, e então o trabalho volta-se para seu aprimoramento de forma a reduzir ainda mais a possibilidade de neurônios disponíveis. A partir da análise das rotinas, considera-se que a aplicação inicial de cinco entradas apresenta o melhor resultado. A versão aprimorada do método seletivo não apresenta mudanças significativas em relação à sua estrutura inicial, mas, assim como esta, apresenta boa modelagem e resultados concretos, podendo ser consideradas opção de manipulação de dados a ser usada em PAs.

I. INTRODUÇÃO

Amplificadores de potência (PA) são dispositivos da área de telecomunicações que têm como função principal aumentar a tensão ou a corrente do sinal de entrada aplicado. Devido ao meio que atuam - como em sistemas isolados, por exemplo - trabalham com baixas potências a fim de manter uma boa linearidade e, portanto, o sinal transportado é da ordem linear. No entanto, em algumas aplicações a potência induzida precisa ser maior para melhorar a eficiência e o sinal transportado passa a ter diferentes ordens. A fim de garantir a linearização desse sinal são empregados métodos de manipulação de dados [1].

Dentre esses, os mais proveitosos na área da elétrica e telecomunicações são aqueles da topologia *Feed Forward*, que trabalham com o carregamento de dados em um único sentido: da entrada à saída. Dessa classe destaca-se o modelo *Group Method Data Handling* (GMDH), que

funciona como uma rede neural dividida em camadas. O GMDH destaca-se por sua capacidade de lidar com alto grau de complexidade e com a mínima intervenção humana, sendo um modelo auto organizável.

Em [2] foram estudados dois métodos para a seleção de coeficientes, um mais rigoroso do que outro. O método intitulado Seletivo, que começa a selecionar os neurônios desde a primeira camada, teve melhor desempenho em relação ao chamado Abrangente. No presente artigo, o objetivo é aprimorar o Seletivo ao reduzir a quantidade de neurônios candidatos a percorrer as camadas da rede.

II. O MODELO GMDH

Foi citado pelas primeiras vezes no fim da década de 1960 [3] e tornou-se promissor no campo da telecomunicação por comportar uma grande quantidade de dados - mesmo em ordem complexa - e apresentar bons resultados a partir do rearranjo de sua rede a cada rotina.

Consiste basicamente em um algoritmo que utiliza neurônios para a manipulação de dados, que são separados em camadas. O número de neurônios em cada camada depende diretamente do valor inserido na entrada da rede, e a partir da segunda camada as entradas tornam-se as saídas da camada anterior, e assim sucessivamente até o fim do algoritmo.

Cada neurônio recebe duas entradas e resulta em apenas uma saída, e dessa forma os dados fluem através da rede, camada a camada, em um único sentido, como mostrado na Fig. 1.

A saída de cada neurônio é calculada pela função de ativação

$$g(x) = m + nx_i + ox_j + px_ix_j + qx_i^2 + rx_j^2 \quad (1)$$

previamente programada, em que m , n , o , p , q e r são coeficientes ajustáveis. O índice i representa a primeira entrada do neurônio e o índice j representa a segunda [3].

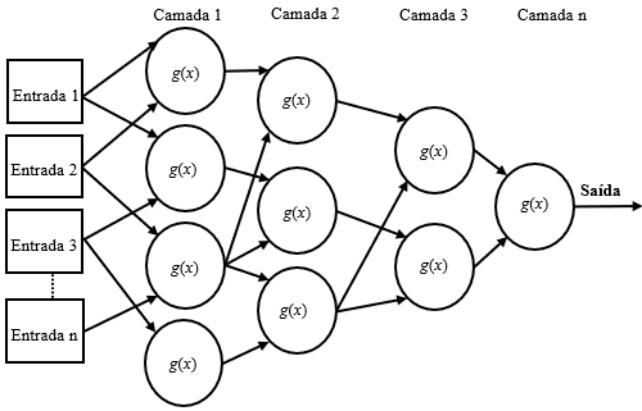


Fig. 1. Rede Neural

III. O GMDH APLICADO NA MODELAGEM PARA PA

Quando a rede neural baseada no GMDH é empregada em PAs, a última camada trabalhada deve convergir para apenas um neurônio e, portanto, resulta em apenas uma única saída no final do cálculo. As entradas aplicadas na rede referem-se aos instantes atual e passados coletados como amostras, e a quantidade de instantes passados utilizada depende diretamente do número de entradas inicial inserido (E), indo de 0 até ($E - 1$).

O número de neurônios de cada camada é definido por

$$Cr = a!/[b!(a - b)!] \quad (2)$$

onde Cr é a quantidade resultante de neurônios na camada, a é o valor de entradas aplicado e b a quantidade inserida em cada neurônio, que geralmente é dois [3]. Na camada 2 as entradas consideradas no cálculo são o número de neurônios da camada 1, e na camada 3 as entradas consideradas são o número de neurônios da camada 2, e assim a lógica segue até a última camada programada.

Quando se trabalha com PAs o sinal envolvido é da ordem complexa, então a função de ativação de cada neurônio deve também ser complexa para o processamento do dado [4]. Dessa forma, a função previamente apresentada é modificada para

$$g(x) = mx_i + nx_j + ox_i/x_i| + px_j/x_j| + qx_i/x_j| + rx_j/x_i| \quad (3)$$

onde m, n, o, p, q e r são coeficientes ajustáveis, i e j permanecem como referências à primeira e segunda entradas do neurônio, e a partir do terceiro termo o módulo da entrada é representada por $|x|$.

IV. MÉTODOS

A. A análise matemática da estrutura dos códigos

A estratégia em usar o modelo GMDH consiste na definição da quantidade de camadas a serem usadas e quais neurônios manter em cada uma delas, a fim de obter o menor erro e melhor resultado ao fim do processamento neural.

O presente projeto trabalha com três camadas de modo a facilitar a análise do comportamento do sinal. Para formar uma opção concreta de manipulação de dados foram construídos dois códigos lógicos que diferem no modo de seleção dos neurônios, mas que extraem coeficientes de forma semelhante.

Apesar de o modelo GMDH ser considerado não linear, pode-se obter com ele resultados lineares se os coeficientes forem extraídos de forma independente a cada camada: obtém-se os coeficientes da primeira camada e, a partir deles, obtém-se os coeficientes da segunda e, por fim, são extraídos os coeficientes da terceira camada. Essa extração é feita por meio de Mínimos Quadrados, do inglês *Least Squares* (LS), que consiste na minimização da soma dos quadrados dos erros [5]. No fim de cada rotina é calculado o Erro Quadrático Médio Normalizado, do inglês *Normalized Mean Square Error* (NMSE), que compara os resultados a cada vez e mantém o menor erro como o melhor, associando os neurônios envolvidos na função. O NMSE é calculado por

$$NMSE = 10 \log \frac{\sum_{n=1}^N |e(n)|^2}{\sum_{n=1}^N |yref(n)|^2} \quad (4)$$

em que N é o número total de amostras e n é o instante referenciado. A diferença entre a saída desejada ($yref(n)$) e a saída estimada (que foi calculada) é representada por $e(n)$.

B. Método Abrangente

O primeiro método, chamado de Abrangente, extrai os coeficientes da camada 1 através de um único LS assumindo a presença de todos os Cr_1 neurônios. Dessa forma, ele começa a selecionar os neurônios a partir da segunda camada: são mantidos dois neurônios fixos na camada 2, e para estes são testadas as possibilidades de combinação de todos os neurônios dessa camada. Assim, o número total de extração de coeficientes por meio de LS é igual ao número de neurônios da camada 2, que é Cr_2 , calculado de acordo com (2). A camada 3 conta com um neurônio fixo apenas, que recebe suas duas entradas e resulta em uma única saída.

C. Método Seletivo

O segundo método, chamado de Seletivo, começa a selecionar neurônios desde a primeira camada, mantendo nela somente aqueles que realmente serão usados para toda a rede neural. A camada 1 pode contar com três neurônios, em que um se repete como entrada da camada 2, como na Fig. 2. Nesse cenário são testadas n_3 possibilidades, que são o triplo de combinação de 3 a 3 do valor de Cr_1 . A Fig. 3 mostra como é realizada a organização desses neurônios: para determinada rotina, cada possibilidade admite a repetição de um único neurônio distinto a ser inserido na camada 2. Um segundo cenário, mostrado na Fig. 4, admite a existência de quatro neurônios na camada 1, em que

nenhum é repetido como entrada da camada 2. Nesse caso, o número de possibilidades de extração é dado por n_4 , que é o triplo de combinação de 4 a 4 do valor de Cr_1 , respeitando a organização de duplas distintas mostrada na Fig. 5. Para ambos os cenários, a rede neural fixa dois neurônios na camada 2 – que terá as entradas de acordo com n_3 e n_4 – e somente um na camada 3. Dessa forma, o método Seletivo conta com a totalidade de $n_3 + n_4$ possibilidades de extração.

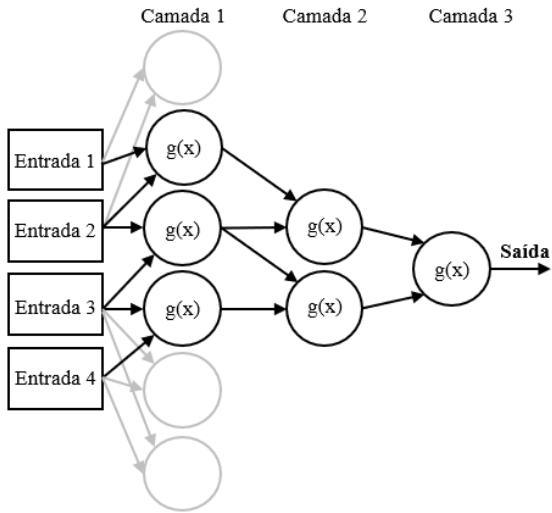


Fig. 2. Repetição de um neurônio na primeira camada

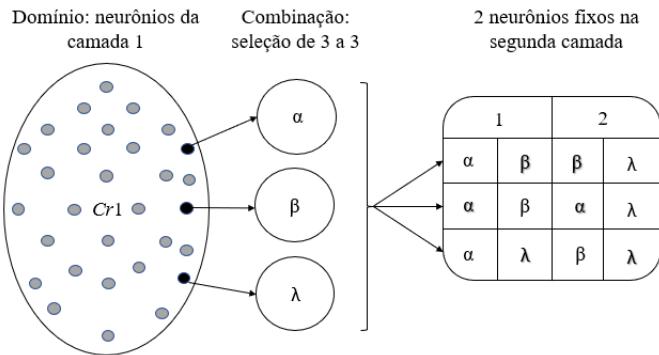


Fig. 3. Cálculo de n_3

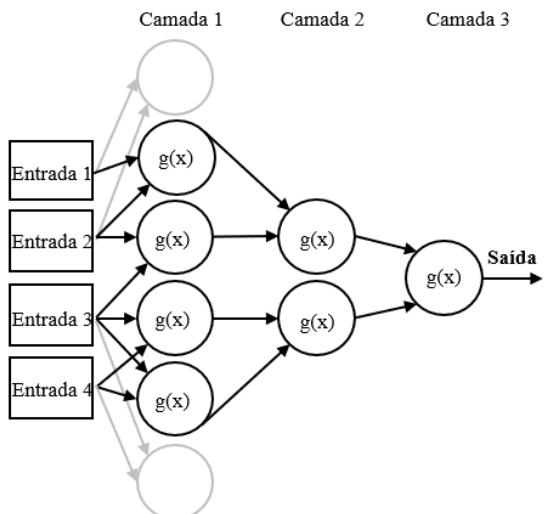


Fig. 4. Uso de quatro neurônios na primeira camada

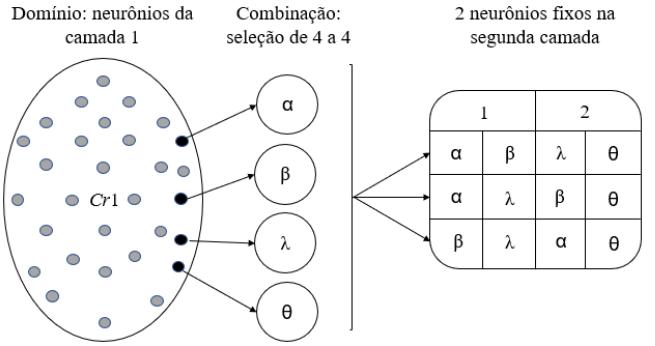


Fig. 5. Cálculo de n_4

Posteriormente, o código Seletivo – ao caracterizar-se como o mais rigoroso na escolha de neurônios – foi aprimorado para diminuir ainda mais o número de possibilidades de extração de coeficientes, sem prejudicar a precisão do código. Inicialmente foram calculados todos os NMSE dos neurônios da primeira camada, de forma individual. Assim, foram realizadas Cr_1 extrações assumindo a presença de apenas 1 neurônio. Em seguida, estes neurônios foram classificados de acordo com seus resultados: os melhores são aqueles que apresentam os menores NMSE. Então cada qual foi direcionado para as camadas seguintes, repetindo o melhor neurônio quando necessário.

V. RESULTADOS

Ambos os códigos foram confrontados durante a realização de diversos testes. O número de entradas foi variado de 3 a 6, e os NMSE de extração e validação foram comparados.

Ao constatar que o método Seletivo apresenta melhores resultados [2], foi investido em seu aprimoramento de modo a diminuir o número de possibilidades de extração e apurar os cálculos. A Tabela I apresenta a comparação dos resultados de extração e validação do método Seletivo, antes e depois do seu aprimoramento, ao variar as entradas de 3 a 6.

TABELA I. MÉTODO SELETIVO

Entradas	Seletivo		Seletivo aprimorado	
	NMSE Ext. (dB)	NMSE Val. (dB)	NMSE Ext. (dB)	NMSE Val. (dB)
3	-31,37	-31,27	-31,24	-31,14
4	-34,89	-35,39	-33,96	-34,13
5	-36,12	-36,66	-35,82	-36,33
6	-36,53	-37,17	-34,99	-22,66

Ao analisar os dados iniciais do método Seletivo nota-se resultados próximos de extração e validação, o que constata a ausência de mau-condicionamento de matrizes. O NMSE é medido em decibéis e tem a ordem de erro praticamente dobrada a cada 3 unidades de diferença, o que reforça a precisão do método.

Ao aplicar as rotinas no método aprimorado, percebe-se que os valores obtidos estão próximos, mas não tão bons

quanto aqueles calculados com maior número de possibilidades, uma vez que esse novo método não é ótimo. Nota-se, também, que o valor de entrada que implica melhores resultados ainda é o 5, e que para 6 entradas há uma grande defasagem entre extração e validação. O que ocorre é que o código mantém as possibilidades calculadas e, a cada aumento de entrada, são acrescentadas mais possibilidades. Tal diferença pode ser explicada pelo fato de que, quando com 6, o código está utilizando uma entrada com maior atraso que não estava disponível na rotina anterior.

A Tabela II mostra os melhores neurônios classificados para número inicial de 5 e 6 entradas e quais são os instantes, atual e passado, que vão usar posteriormente. Ressalta-se que, para 5 entradas, o maior atraso possível a ser utilizado é o de $n - (E - 1)$, ou seja, $n - 4$.

TABELA II. INSTANTES UTILIZADOS EM 5 E 6 ENTRADAS

Neurônios 5 entradas	Instantes utilizados	Neurônios 6 entradas	Instantes utilizados
4	$n, n - 4$	4	$n, n - 4$
3	$n, n - 3$	3	$n, n - 3$
2	$n, n - 2$	5	$n, n - 5$
1	$n, n - 1$	2	$n, n - 2$

Com o cômputo do neurônio 5, a rotina para 6 entradas utiliza um momento anterior não disponível no último cálculo, o que justifica a defasagem para esse valor inicial.

A Fig. 6 mostra graficamente a comparação entre a saída desejada e a saída obtida com o método Seletivo aprimorado, com a aplicação de 5 entradas (que apresentou melhores resultados), em qual é perceptível a proximidade dos dados. Foram plotadas cerca de quarenta amostras do tipo *floating-point double precision*, em que a diferença final entre as saídas obtida e desejada resulta em um vetor de tamanho 3221.

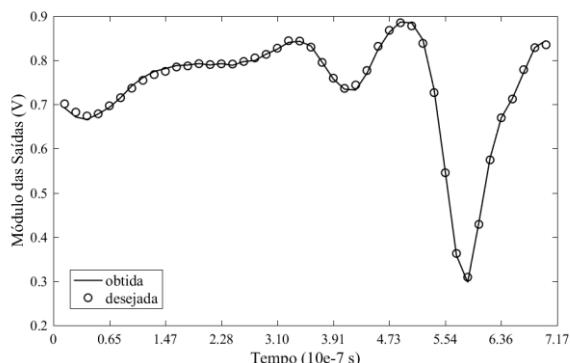


Fig. 6. Módulos das saídas no método Seletivo aprimorado

Em suma, o método Seletivo escolhe com rigor os dados a serem inseridos na rede a partir da camada 2, analisando tanto o cenário com repetição como o sem

repetição. Para 3 entradas, somente o caso com repetição de neurônios é admissível, enquanto que para a variação de 4 a 6 entradas ambos os casos são testados e o cenário sem repetição se sobressai. A partir disso, o Seletivo é aprimorado para diminuir suas possibilidades de extração, e os resultados são analisados de modo empírico: qual o melhor custo-benefício, considerando o aumento exponencial de complexidade com a maior variação de entradas.

VI. CONCLUSÃO

Uma vez estudada a relevância da linearização de sinais de PAs, nota-se a importância de voltar o estudo de manipulação de dados também para a área da telecomunicação.

Os dois códigos construídos e comentados no presente trabalho têm como finalidade garantir a linearização dos sinais com os menores erros possíveis. A partir do confronto, o método Seletivo é considerado sobressalente ao Abrangente e, com isso, o objetivo passa a ser a redução de possibilidades de seleção para tornar o método ainda mais criterioso.

Obtém-se uma nova estrutura – aprimorada – para o método Seletivo ao criar novas rotinas com redução do número de neurônios candidatos para entrar no cálculo de extração. Igualmente ao método anterior, considerando a complexidade da realização de cada teste, admite-se que a aplicação de 5 entradas configura no melhor resultado. A análise da nova sintaxe mostra que o método não é ótimo, mas apresenta bons resultados, pequenos erros e pode-se considerar que este método é uma opção de manipulação de dados a ser aplicada em PAs.

AGRADECIMENTOS

Os autores gostariam de manifestar seu agradecimento pelo suporte financeiro provido pelo Conselho Nacional de Desenvolvimento Científico e Tecnológico (CNPq) e pela Fundação Araucária de Apoio ao Desenvolvimento Técnico Científico e Tecnológico do Estado do Paraná, no âmbito do Programa PIBITI UFPR 2020.

REFERÊNCIAS

- [1] ZANELLA, A. F. Modelagem comportamental de amplificadores de potência de radiofrequência baseada no método de grupo de manipulação de dados. Curitiba, 2020.
- [2] MACHADO, A. P. P.; LIMA, E. G. Selective Algorithm for Group Method of Data Handling Applied to Power Amplifier Modeling. SFORUM, 2021.
- [3] IVAKHNENKO, A. G. The group method of data handling in long-range forecasting. Technological Forecasting and Social Change, v. 12, 2-3 1978.
- [4] KIM, T.; ADALI, T. Fully complex multi-layer perceptron network for nonlinear signal processing. Journal of VLSI Signal Processing Systems for Signal, Image, and Video Technology, v. 32, 1-2 2002. ISSN 13875485. DOI: 10.1023/A : 1016353216361.
- [5] MATHEWS, J.; SICURANZA, G. 2000. Polynomial signal processing. John Wiley & Sons, Inc.