

Algoritmo Seletivo com Diferentes Métodos de Extração para Modelagem de Amplificador de Potência Baseada em GMDH

Ana Paula Princival Machado¹, Eduardo Gonçalves de Lima²

¹ UFPR, Curitiba, Brasil

² UFPR, Curitiba, Brasil

anaprincival@ufpr.br

Resumo—Amplificadores de Potência (PAs) são dispositivos que devem atuar com alta eficiência a fim de otimizar o consumo de energia do meio em que estão empregados. São utilizados métodos de linearização de dados para reparar situações que demandam maior potência (quando o sinal atinge maiores ordens). Dessa forma, o presente artigo apresenta o método Seletivo, que é uma rede neural inteligente baseada em *Group Method of Data Handling* (GMDH), construída por meio de programação no MATLAB, que tem por finalidade modelar o comportamento do PA. A partir do seu bom desempenho, a rede é submetida a três métodos diferentes de extração de coeficientes a cada camada: mínimos quadrados separáveis, otimização não linear e o método iterativo. A topologia de cada método é treinada e analisada, a fim de entender o comportamento do código nesses diferentes cenários e buscar pelo melhor desempenho. Com os resultados obtidos, com erros na ordem de -35 dB, conclui-se que todos os métodos utilizados proporcionam um bom funcionamento do Seletivo. No entanto, o método de otimização não linear apresenta a melhor precisão, pois extrai os coeficientes de todas as camadas simultaneamente.

I. INTRODUÇÃO

Um importante fator a ser considerado em projetos de engenharia elétrica é a otimização do consumo de energia de dispositivos e dos sistemas em quais estão localizados. O amplificador de potência (PA), por exemplo, é comumente utilizado na área de telecomunicações e radiofrequência. Tem por objetivo aumentar a potência aplicada à sua entrada, e idealmente transporta o sinal de forma linear a fim de manter a qualidade do serviço na aplicação em que atua [1].

No entanto, nos casos em que são atingidas maiores ordens, a fim de manter a eficiência energética busca-se empregar métodos de linearização para corrigir a situação. O presente trabalho, portanto, aborda o uso de redes neurais para a manipulação de dados, com aplicação na modelagem

e linearização de PAs, com enfoque na topologia *Group Method of Data Handling* (GMDH).

A rede GMDH é uma rede da topologia *Feed Forward*, que faz o processamento do sinal de forma unidirecional. O modelo foi inicialmente desenvolvido por volta da década de 70 por um professor ucraniano, tornando-se notável pela sua capacidade de organização com a mínima intervenção humana. Também é caracterizada pela precisão dos resultados, alcançada mesmo com a inserção de um grande conjunto de dados [2]. Diante dessas vantagens, a GMDH é usada como base para construir a modelagem dos dados do PA.

Em [3] foram construídos dois códigos baseados em GMDH, intitulados de Abrangente e Seletivo. Ambos têm por objetivo linearizar dados de um PA, e diferem na sua forma de escolha de neurônios. O método Seletivo, projetado para ser mais rigoroso, apresenta melhor desempenho ao resultar em valores mais baixos de *Normalized Mean Square Error* (NMSE) [3], e dessa forma ele torna-se o modelo principal para o avanço do estudo.

Com isso, o presente artigo explora três métodos diferentes de extração de coeficientes no método Seletivo: mínimos quadrados separáveis, método de otimização não linear e método iterativo. Por fim, esses métodos serão comparados e seus desempenhos serão justificados de acordo com suas respectivas vantagens e limitações.

II. O MÉTODO SELETIVO

Consiste numa rede neural separada em três camadas, em que cada uma possui certo número de neurônios. Cada neurônio recebe duas entradas e resulta em uma saída, e assim as saídas de determinada camada serão usadas como entradas na próxima. Há uma função de ativação em cada neurônio, responsável por manipular os dados inseridos nele, dada por

$$g(x) = mx_i + nx_j + ox_i/x_i/ + px_j/x_j/ + qx_i/x_j/ + rx_j/x_i/ \quad (1)$$

em que m, n, o, p, q e r são coeficientes ajustáveis a serem extraídos e x_i e x_j referem-se à primeira e segunda entrada, respectivamente.

A primeira camada possui Cr_1 número de neurônios, calculado por

$$Cr_1 = E! / [2!(E - 2!)], \quad (2)$$

em que E é a quantidade de entradas aplicada na rede. A segunda camada possui dois neurônios fixos, enquanto a camada três conta com um único neurônio, que recebe as duas saídas da segunda camada e resulta na saída final.

Com isso, os dois neurônios α e β fixos na segunda camada necessitam, juntos, de quatro entradas (duas para cada um). Essas quatro entradas serão selecionadas do conjunto Cr_1 , podendo ser todas distintas entre si, ou havendo a possibilidade de uma ser utilizada para ambos os neurônios. Dessa forma tem-se dois cenários: o com repetição, como mostrado na Fig. 1, e o sem repetição, como mostrado na Fig. 2. Em [3] vê-se que o cenário sem repetição sempre apresenta melhores resultados, e assim são usados quatro neurônios distintos.

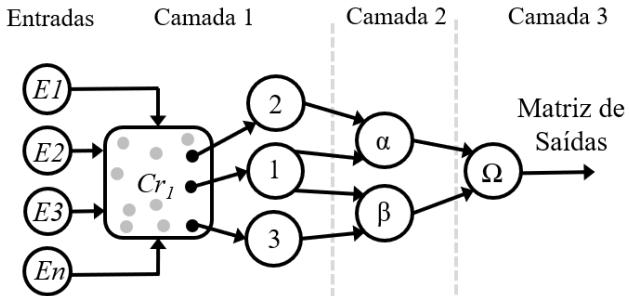


Fig. 1. Método Seletivo com repetição

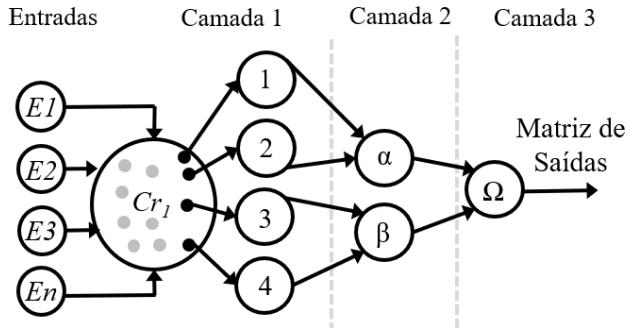


Fig. 2. Método Seletivo sem repetição

Por fim, a matriz de saídas final, obtida ao fim da terceira camada, é utilizada no cálculo do NMSE, dado por

$$NMSE = 10 \log \frac{\sum_{n=1}^N |e(n)|^2}{\sum_{n=1}^N |yref(n)|^2}, \quad (3)$$

em que n refere-se ao instante das amostras (partindo do conjunto de amostras obtidas do PA) e N representa a

quantidade total delas. A saída desejada é representada por $yref(n)$, enquanto $e(n)$ denota a diferença entre saída desejada e estimada.

III. EXTRAÇÃO DE COEFICIENTES POR MEIO DE DIFERENTES MÉTODOS

Nesta seção serão explicados separadamente os métodos extração de coeficientes, que foram desenvolvidos por meio de programação. Para os testes é utilizada uma amostra com 3221 instantes de entrada.

A. Mínimos Quadrados Separáveis

Este método foi utilizado na construção dos modelos originais de Abrangente e Seletivo, que auxiliaram na análise da eficiência de ambos. Consiste em encontrar o melhor ajuste para um conjunto de dados, minimizando a soma dos quadrados das diferenças entre os dados obtidos e estimados, encontrando-se os coeficientes de uma única camada por vez. No software MATLAB [4] isso pode ser efetuado por meio do comando "\\", conforme ilustrado na Fig. 3.

$$\boxed{\text{Coeficientes da camada}} = \boxed{\text{Matriz de dados da camada}} \setminus \boxed{\text{Saída do PA}}$$

Fig. 3 – Extração por meio de Mínimos Quadrados Separáveis

Como a função de ativação (2) contida em cada neurônio possui 6 termos, a primeira camada possuirá uma matriz de dados de 24 colunas (6 colunas para cada neurônio). A matriz da segunda camada possui 12 colunas por conta de seus dois neurônios fixos, e a matriz da terceira camada tem 6 colunas devido ao único neurônio, e estas matrizes são os conjuntos estimados. Os dados desejados (o alvo) são a saída do PA, e com isso é possível extraír os mínimos quadrados e obter os coeficientes da respectiva camada.

B. Otimização não linear

Para aplicar este método foi utilizado o comando *lsqnonlin*, do MATLAB, que resolve problemas de mínimos quadrados de dados não lineares. Para aplicá-lo, é necessário inserir em seus parâmetros uma função e uma estimativa inicial de resultado.

Com isso foram montadas quatro funções “assertivas”, que são essencialmente o cenário mais eficiente do método Seletivo para cada valor de entrada. Em cada função foi passado como parâmetro único (indicado como S) os coeficientes de todas as camadas. Assim, a entrada da função são os coeficientes antigos, e ao atingir o critério de avaliação, definido o módulo da diferença entre a saída estimada e a desejada, são retornados novos coeficientes.

Dessa forma, o *lsqnonlin* faz iterações até achar um mínimo (local, podendo ou não ser global), que leve a uma situação próxima à ideal. Assim, são retornados novos

coeficientes, que são utilizados no cálculo do NMSE atualizado.

O *lsqnonlin* é um procedimento matemático que busca um erro mínimo, mas uma vez que o sistema não tem solução – pois tem mais equações do que incógnitas –, este erro não é zero. Uma descrição visual do método pode ser vista na Fig. 4.

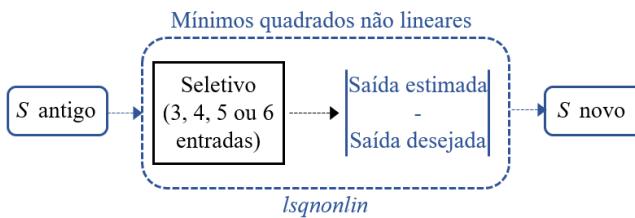


Fig. 4 – Extração por meio de otimização não linear

C. Método Iterativo

Consiste basicamente em procurar pela solução de um problema inverso: a saída e os coeficientes do cenário mais assertivo são conhecidos, então busca-se pelos dados de entrada que resultem nessa condição.

De forma geral, sabe-se quais são os coeficientes e a saída da terceira camada que levam ao menor NMSE, quando o método Seletivo é treinado pela forma original. O método iterativo, então, busca pela otimização das entradas da camada três, que neste caso são as saídas da segunda camada. Uma ilustração pode ser vista na Fig. 5, onde *Entradas*, *Saída* e *coef* são conhecidos do melhor cenário.

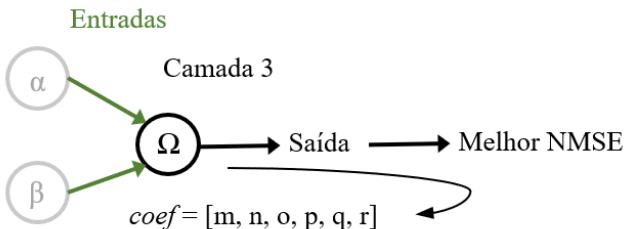


Fig. 5 – Estrutura conhecida do cenário que leva ao melhor NMSE

Assim, de posse das saídas da segunda camada, estas são passadas como parâmetro para uma função Processamento. A função abrange o treinamento da terceira camada (em que os coeficientes previamente extraídos no melhor cenário são carregados) e seu retorno é a diferença entre a saída estimada da camada e a saída desejada da rede.

Para a execução é utilizado o comando *fsolve* do MATLAB, que é um método de solução algébrico não linear. Resolve um problema especificado por $F(x) = 0$ para x , onde $F(x)$ é uma função que retorna um valor vetorial. O comando recebe Processamento e a estimativa inicial (as saídas da segunda camada obtidas no melhor cenário), e busca pelo menor valor retornado, ou seja, a menor diferença entre as saídas desejada e estimada. Então apresenta a entrada da terceira camada (e assim a saída da segunda camada) ideal, que levam ao erro mínimo, o que se intitula como “solução do problema inverso”, ou solução do P. I. Uma vez que o sistema possui solução (há menos equações do que incógnitas), este erro tende a zero.

A partir desta iteração o Seletivo é retrainado a fim de obter novos coeficientes da segunda camada. Desta vez, no

entanto, os dados desejados utilizados nos mínimos quadrados é a solução do problema inverso, e com isso obtém-se um novo NMSE ao final da rede neural. Todo o procedimento pode ser repetido, a fim de que a cada iteração o erro seja ainda menor. A estrutura do método iterativo pode ser vista na Fig. 6.

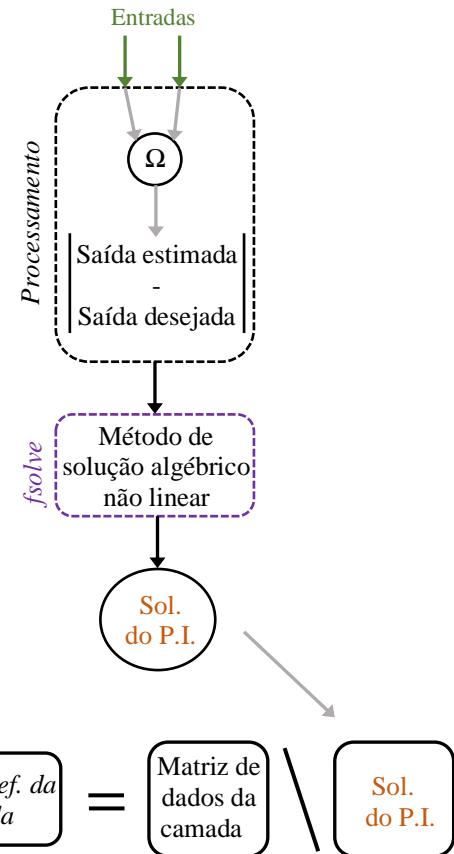


Fig. 6 – Lógica do método Iterativo

IV. RESULTADOS

Todos os códigos e simulações foram efetuados no software MATLAB, com amostras oriundas de um PA de classe AB, que emprega um semicondutor HEMT fabricado em tecnologia GaN. A frequência da portadora foi setada em 900 MHz, modulada por um sinal de envoltória WCDMA com aproximadamente 3,84 MHz de largura de banda. Para a medição dos dados de entrada e saída foi utilizado um analisador de sinal vetorial do tipo Rohde & Schwarz FSQ, com 61,44 MHz como frequência de amostragem [5]. Os vetores utilizados como entrada e saída possuem 3221 instantes de extração, e 2001 instantes de validação.

A fim de evitar erros devido à inicialização dos códigos, foi arbitrariamente escolhida a remoção dos dez primeiros instantes em todos os cálculos. Dessa forma, a Tabela I mostra os resultados de NMSE de extração e validação obtidos com o método dos Mínimos Quadrados Separáveis, que atinge -36,5 dB no melhor NMSE de extração. Em seguida, a Tabela II mostra os resultados obtidos com a otimização não linear, que apresenta -37,2 dB no NMSE de extração no melhor desempenho. Por fim a Tabela III

mostra os NMSE obtidos com o método Iterativo, chegando a -35 dB nas últimas iterações.

TABELA I. EXTRAÇÃO DE COEFICIENTES POR MEIO DE MÍNIMOS QUADRADOS SEPARÁVEIS

Método Seletivo		
Entradas	NMSE Ext. (dB)	NMSE Val. (dB).
3	-31,38	-31,26
4	-34,90	-35,38
5	-36,12	-36,65
6	-36,53	-37,15

TABELA II. EXTRAÇÃO DE COEFICIENTES POR MEIO DE OTIMIZAÇÃO NÃO LINEAR

Método Seletivo		
Entradas	NMSE Ext. (dB)	NMSE Val. (dB).
3	-31,77	-31,72
4	-36,04	-36,53
5	-36,67	-37,22
6	-37,20	-37,85

TABELA III. EXTRAÇÃO DE COEFICIENTES POR MEIO DO MÉTODO ITERATIVO

Método Seletivo – 4 entradas		
Iteração	NMSE Ext. (dB)	NMSE Val. (dB).
1	-34,90	-35,38
2	-34,95	-35,43
3	-34,97	-35,43
4	-34,99	-35,45
5	-35,00	-35,47
6	-35,01	-35,48
7	-35,02	-35,49

Pode-se notar que em todos os métodos há proximidade entre os erros de extração e validação, além de apresentarem rotinas que levam a valores em torno de -35 dB, o que é consideravelmente baixo devido ao comportamento da escala logarítmica (uma diminuição de 3 dB reduz o erro à sua metade). Também se pontua que o aumento da quantidade de entradas faz com que haja uma tendência para o NMSE diminuir. Isso ocorre devido à presença de mais possibilidades de organização da rede, permitindo um arranjo mais eficiente de neurônios. No entanto, ressalta-se que o aumento do número de entradas implica o aumento do custo computacional das simulações.

No método iterativo a escolha de 4 entradas foi arbitrária, visando inicialmente o menor esforço computacional durante o treinamento da lógica. Foram feitas rotinas até certificar-se de que não haveria mudanças significativas no NMSE entre uma e outra, e dessa forma foram totalizadas 7 iterações. Com a análise dos dados apresentados, considera-se que o iterativo não é um método ótimo, pois encontra coeficientes individualmente para cada camada, considerando fixos os valores dos coeficientes das demais camadas.

De forma geral, o método de extração por meio de otimização não linear apresenta os melhores resultados, uma vez que busca o ótimo e fornece os coeficientes de todas as camadas de uma só vez (considera que os coeficientes de todas as camadas podem variar ao mesmo tempo).

V. CONCLUSÃO

No presente artigo foi apresentado o código Seletivo, que é um método de linearização de dados baseado no modelo GMDH, consistindo numa rede neural inteligente. É organizado em camadas, em que cada camada possui uma certa quantidade de neurônios, que são processados e têm seus respectivos coeficientes extraídos, a fim de produzir uma saída a ser usada como entrada na próxima camada.

Dessa forma, sabe-se que o Seletivo (previamente detalhado e treinado com dados do PA) é capaz de operar próximo do ideal, produzindo erros pequenos. Assim, o código foi explorado ao ser submetido a diferentes métodos de extração de coeficientes a cada camada: mínimos quadrados separáveis, otimização não linear e método iterativo.

Os resultados apresentados mostram que os diferentes cenários permanecem apresentando bons resultados, na ordem de -35 dB, mas cada qual com sua particularidade: resultados mais precisos e diferente custo-benefício em questão de treinamento. De modo geral, o método de otimização não linear apresenta o menor erro de modelagem – exigindo maior esforço –, uma vez que faz a extração de coeficientes de uma só vez, chegando a -37 dB no erro de extração.

AGRADECIMENTOS

Os autores gostariam de agradecer o suporte financeiro provido pelo Conselho Nacional de Desenvolvimento Científico e Tecnológico (CNPq) sob o programa PIBIC UFPR 2021.

REFERÊNCIAS

- [1] S. Cripps, RF power Amplifiers for Wireless Communications, 2nd edition. Norwood, MA: Artech House, 2006.
- [2] IVAKHNENKO, A. G. The group method of data handling in long-range forecasting. Technological Forecasting and Social Change,v. 12, 2-3 1978.
- [3] MACHADO, A. P. P.; LIMA, E. G. . Selective Algorithm for Group Method of Data Handling Applied to Power Amplifier Modeling. In: XXI Microelectronics Students Forum, 2021, Campinas. Proceedings of the XXI Microelectronics Students Forum, 2021. p. 1-4
- [4] C. Moler, Numerical Computing with MATLAB. Philadelphia: SIAM, 2004.
- [5] BONFIM, E.; LIMA, E. G. A modified two dimensional Volterra-based series for the low-pass equivalent behavioral modeling of RF power amplifiers. Progress In Electromagnetics Research M, Vol. 47, 27-35, 2016.